

SEGUNDO AVANCE PROYECTO VISIÓN DE MÁQUINA

Mateo Andres Rodriguez Pereira
Sebastian Hernando Campiño Figueroa



UNIVERSIDAD NACIONAL DE COLOMBIA
Facultad de Ingeniería
2023

- 1. PROPONENTES:** Mateo Andres Rodriguez Pereira y Sebastian Hernando Campiño Figueroa
- 2. ASIGNATURA:** Visión de maquina
DEPARTAMENTO: Departamento De Ingeniería Eléctrica y Electrónica
- 3. TITULO:** Identificación de posibles zonas criticas en imágenes termográficas mediante procesamiento de imágenes.

4. JUSTIFICACIÓN:

La termografía es una técnica que permite medir de forma remota la temperatura superficial de un objeto, visualizándola a través de imágenes termográficas (Caciotta et al., 2014; Didier, 2017; Korendo & Florkowski, 2001; Ullah et al., 2020). Estas imágenes son representaciones visuales de la distribución de temperatura en una superficie, donde cada color representa un rango de temperatura diferente. La termografía tiene aplicaciones diversas, como herramienta diagnóstica en la medicina, la detección de fallas en componentes electrónicos, la inspección de edificaciones, y la investigación científica.(Caciotta et al., 2014; Didier, 2017; Korendo & Florkowski, 2001; Ullah et al., 2020).

El análisis de las imágenes termográficas es esencial para interpretar correctamente la información contenida en ellas y extraer conclusiones válidas. Tradicionalmente, este análisis se ha realizado de forma manual por expertos, lo que puede ser un proceso lento, costoso, y sujeto a errores humanos. Sin embargo, su importancia radica en ser una técnica de inspección no destructiva con un amplio campo de acción. (Didier, 2017; Ullah et al., 2020). Por lo tanto, existe una necesidad imperante de desarrollar métodos automáticos y precisos para analizar imágenes termográficas, con el fin de mejorar la eficiencia y la precisión del proceso de análisis.

La inspección no destructiva (IND), también conocida como ensayo no destructivo (END), es un conjunto de técnicas y métodos utilizados para evaluar la integridad, calidad y seguridad de materiales, componentes y estructuras sin causar daño permanente o destrucción en el objeto bajo prueba. Las termografías son un tipo de ensayo no destructivo y su relevancia como ensayo es que permite detectar variaciones de temperatura en la superficie de los objetos, lo que puede indicar defectos, puntos calientes o problemas de aislamiento.

El objetivo de este proyecto es desarrollar un sistema automatizado para el análisis de imágenes termográficas utilizando técnicas avanzadas de procesamiento de imágenes. Se buscará segmentar las imágenes en regiones homogéneas y detectar puntos críticos donde el delta de color, que representa diferencias de energía, sea significativo entre regiones. Al automatizar este proceso, se espera reducir el tiempo y los recursos necesarios para el análisis de imágenes termográficas, a la vez que se incrementa la precisión y la objetividad de los resultados obtenidos.

La importancia de este proyecto radica en su potencial para transformar la forma en que se analizan las imágenes termográficas en diversas áreas de aplicación. En la industria, podría utilizarse para detectar de manera eficiente defectos o fallas en componentes y materiales, contribuyendo a la prevención de fallos y accidentes. Además, este proyecto busca contribuir al avance del conocimiento en el campo del procesamiento de imágenes y la termografía, al desarrollar métodos novedosos y eficientes para el análisis de imágenes termográficas.

En conclusión, este proyecto propone desarrollar una herramienta para el análisis de imágenes termográficas que busca generar alertas de forma automática en secciones particulares de interés,

en este caso con deltas de color muy altos.

5. ANTECEDENTES:

El campo del análisis de imágenes termográficas ha experimentado avances considerables, marcados por innovaciones metodológicas y la diversificación de sus aplicaciones en distintas áreas. El desarrollo metodológico en este campo recientemente se ha visto impulsado con herramientas de inteligencia artificial. En Ullah et al. (2020) se desarrolla la integración de una red convolucional con parámetros de temperatura puntual para aplicaciones eléctricas.

En general la aplicación de las técnicas de prevención, predicción y corrección de fallos en la industria se encuentra enfocada en el campo eléctrico y electrónico. En Korendo y Florkowski (2001) y Ullah et al. (2020) se realiza el análisis de fallos en redes de alta y media tensión y en Caciotta et al. (2014) en circuitos eléctricos.

Tomita y Chew (2022) realiza una revisión exhaustiva evaluando más de 200 piezas de literatura sobre la aplicación de termografía para encontrar delaminaciones en edificios. Busca los factores más importantes para la detección y precisión de la información contenida en las termografías y orientar hacia la definición de criterios estándar para el proceso.

En la industria aeroespacial Ciampa et al. (2018) utiliza la termografía para la inspección de estructuras primarias y secundarias de aviones y helicópteros, piezas de motores de aviones, componentes de naves espaciales y sus subsistemas. De forma diferencial, enriquece las imágenes termográficas usadas mediante la aplicación de ondas ultrasonicas, lasers y radiación optica como lasers.

Torres-Galván et al. (2022) propone el uso de redes neuronales convolucionales profundas (CNN) con aprendizaje por transferencia para clasificar automáticamente termogramas en dos clases: normal y anormal. El estudio, realizado con una población de 311 mujeres, utiliza la termografía infrarroja para detectar anomalías en los patrones de temperatura indicativos de patologías mamarias, incluido el cáncer de mama.

Liu et al. (2022) aborda problemas en la detección de fisuras en pavimentos de asfalto mediante CNN, como el equilibrio entre precisión y complejidad, y la distinción entre fisuras y la superficie del pavimento. El trabajo propone un método robusto de detección de fisuras basado en CNN e Infrared Thermography (IRT) y construye un conjunto de datos de referencia abierto para la detección de fisuras bajo diferentes condiciones y periodos del día. Los resultados muestran que las CNN, especialmente el modelo Feature Pyramid Networks (FPN), en combinación con IRT, ofrecen un rendimiento estable y preciso en diferentes condiciones, siendo una opción prometedora para la detección de fisuras en pavimentos.

6. DELIMITACIÓN DEL PROBLEMA:

Dadas las limitaciones de tiempo, se define realizar la detección automática de deltas de color, análogos a los deltas de temperatura, en imágenes termográficas que permitan identificar secciones de posible riesgo en diferentes equipos y ambientes industriales. A futuro se espera expandir el desarrollo a un sistema de supervisión automático que permita identificar fallas en sistemas y subsistemas supervisados.

7. OBJETIVOS:

Objetivo Principal:

Inspección no destructiva. Detección de fallas en Equipos Industriales mediante Termografías: Desarrollar un sistema de visión por computadora que pueda identificar y localizar defectos y anomalías en equipos industriales utilizando imágenes termográficas, con el fin de mejorar la seguridad y eficiencia en operaciones industriales.

Objetivos específicos:

- Segmentar en regiones homogéneas de las termografías obtenidas.
- Obtener el rango de temperaturas de cada termografía de manera automática.
- Relacionar el mapa de color con el valor correspondiente de temperatura.
- Obtener los deltas de temperatura entre cada una de las secciones.
- Detección de anomalías a partir de las secciones y de la diferencia de temperatura

8. MATERIALES Y MÉTODOS:

- Imagen termográfica, también conocida como termografía o imagen térmica, es un tipo de representación visual que muestra la distribución de la temperatura en una escena o objeto mediante la detección de la radiación infrarroja emitida por las superficies. En lugar de mostrar colores basados en la luz visible, como en las fotografías convencionales, las imágenes termográficas utilizan una paleta de colores donde cada tono representa una temperatura específica. Esta tecnología permite visualizar y cuantificar las variaciones de temperatura en una imagen, lo que resulta invaluable en aplicaciones como la detección de problemas térmicos, la inspección de equipos eléctricos y mecánicos, y la identificación de áreas críticas en entornos industriales y de mantenimiento preventivo.

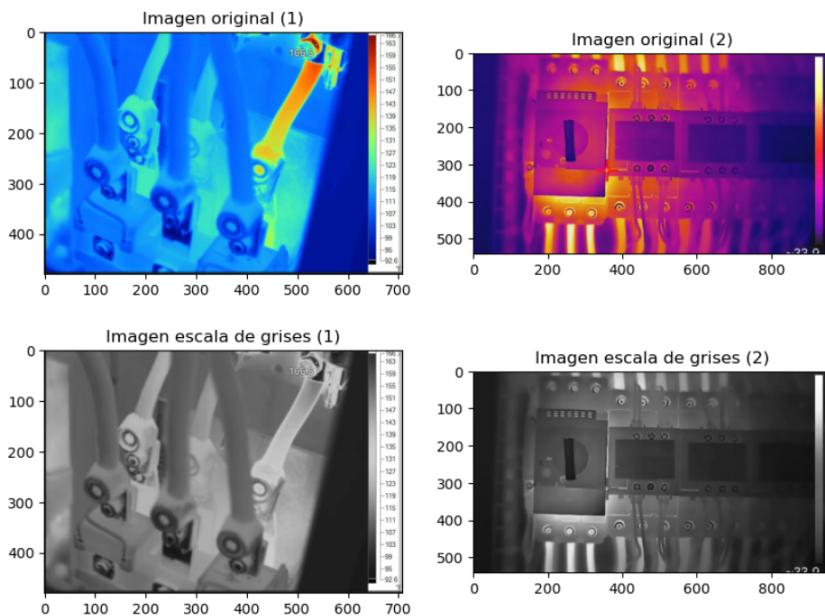


Figura 1: Temografía con paleta arco iris y hierro

- Histogramas: Los histogramas son herramientas cruciales para analizar la distribución de intensidades en las imágenes termográficas. En este proyecto, los histogramas permiten identificar patrones de temperatura anormales y resaltar cambios significativos en la intensidad térmica, lo que es esencial para detectar zonas críticas.
- Filtros para Detección de Bordes (Sobel, Laplacian, Canny): Los filtros de detección de bordes, como Sobel, Laplacian y Canny, son fundamentales para realzar bordes y detalles en las imágenes termográficas. Ayudan a identificar cambios abruptos de temperatura, lo que es esencial para detectar problemas críticos en instalaciones eléctricas y maquinaria.
- Segmentación (Basada en Umbrales, en Regiones y con Canny): La segmentación es esencial para identificar áreas de interés en las imágenes termográficas. Las técnicas de segmentación basadas en umbrales, regiones y el operador Canny permiten separar automáticamente las zonas críticas del fondo y resaltar características relevantes, lo que facilita la detección y el análisis.
- Modelos de Color: Los modelos de color proporcionan información multiespectral en las imágenes termográficas. Al separar y analizar los canales de color, se puede identificar patrones específicos de temperatura y anomalías que no serían evidentes en imágenes en escala de grises. Esto mejora la capacidad de detección y análisis, especialmente en situaciones donde las diferencias de temperatura se manifiestan en cambios de color, como lo es con las imágenes termográficas.
- Tesseract OCR (pytesseract): Python-tesseract es una herramienta de reconocimiento óptico de caracteres (OCR) para Python. Es decir, reconoce “lee” el texto incrustado en imágenes. Esta biblioteca es útil para extraer texto de regiones de interés definidas previamente.

En conjunto, estos componentes y técnicas de procesamiento de imágenes en Python con OpenCV son esenciales para desarrollar un sistema efectivo de detección de zonas críticas, permitiendo una inspección precisa y automatizada en entornos industriales. La combinación de histogramas, filtros de detección de bordes, segmentación y modelos de color permite identificar problemas térmicos y mecánicos, contribuyendo a la seguridad y el mantenimiento preventivo en instalaciones y maquinaria industrial.

Para la continuación del proyecto se planea hacer uso de aprendizaje Profundo (Redes Neuronales Convolucionales - CNN) ya que es una herramienta útil para la detección de patrones en imágenes, incluyendo la detección de zonas críticas en termografías. Para esto, se necesitará un conjunto de datos etiquetado que incluya termografías con zonas críticas identificadas. Esto se abordará en la última etapa del proyecto.

9. DESARROLLO Y RESULTADOS:

- Histogramas

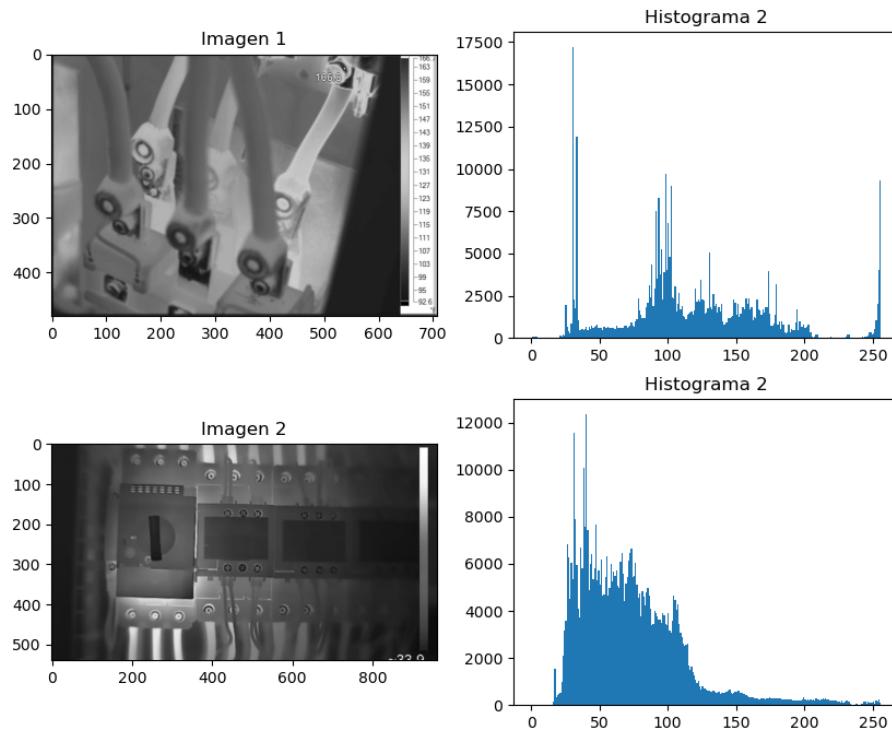


Figura 2: Imagenes con sus histogramas

En los histogramas podemos observar que para la imagen que originalmente está en la paleta arcoiris, dicho histograma no nos da mucha información sobre la distribución de las temperaturas porque al pasar de color a escala de grises en esta paleta, los grises no representan la temperatura de la imagen original, respecto a la imagen 2 que está en paleta hierro, esta imagen si representa al cambiar de color a escala de grises las temperaturas. Estos histogramas son de utilidad debido a que en el caso de la termografía en paleta hierro podemos identificar la intensidad térmica, definir umbrales, entre otras.

- Filtros para detección de bordes

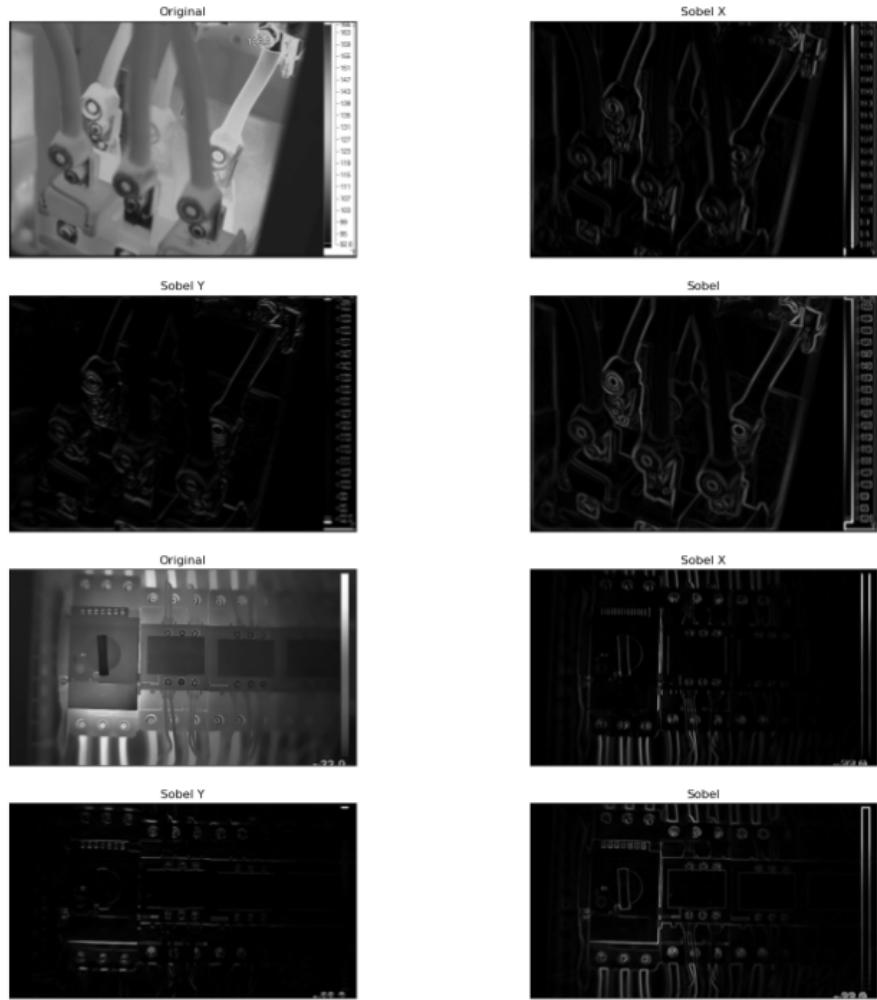


Figura 3: Filtro Sobel

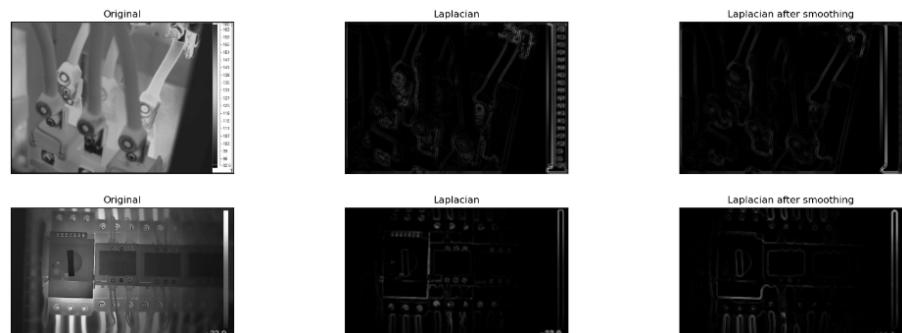


Figura 4: Filtro Laplacian

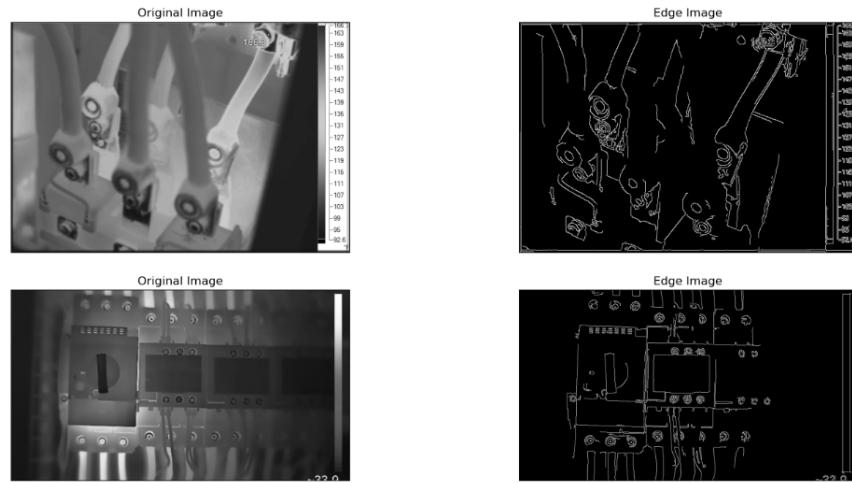


Figura 5: Filtro Canny

De esta forma podemos ver que el filtro Canny, nos permite según los límites propuestos encontrar bordes de una manera bastante aceptable para identificar objetos en las imágenes y posteriormente realizar segmentación, en contraste el resto de filtros no presentan real utilidad para el proyecto.

■ Segmentación

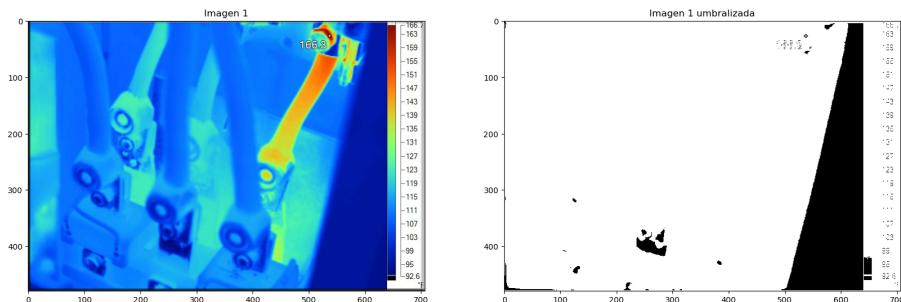


Figura 6: Umbralización

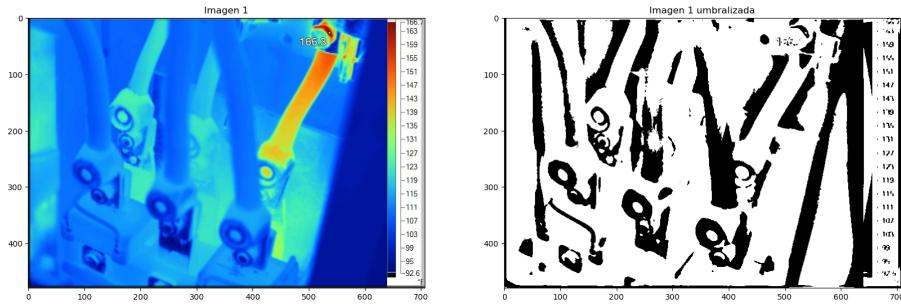


Figura 7: Umbralización Adaptativa

Como se observa en los resultados de las umbralizaciones, la umbralización global no nos permite obtener información relevante, sin embargo la umbralización adaptativa genera resultados mejores, puntualmente tiene utilidad en la imagen con paleta de color hierro, debido a que la escala de grises en la paleta arco iris no es correspondiente a su versión en color, la información que se obtiene de las umbralizaciones no es de utilidad en este caso.

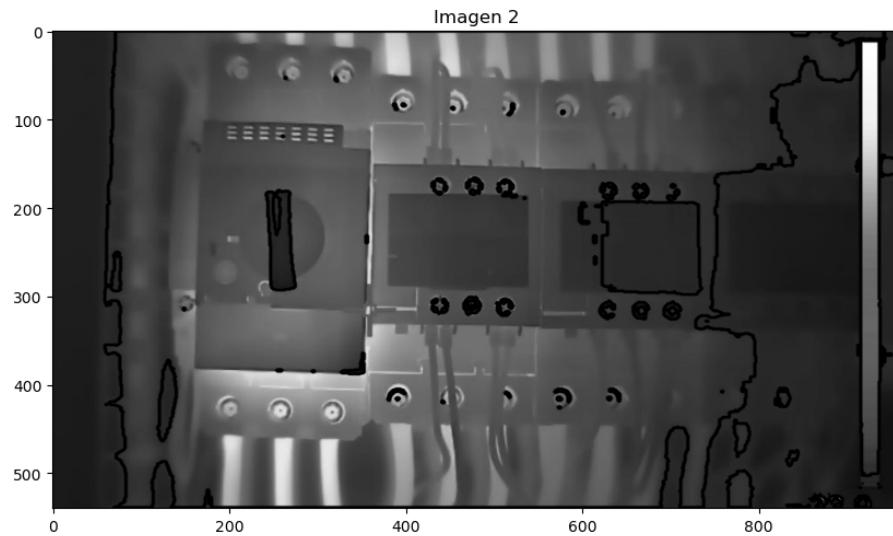


Figura 8: Segmentación basada en regiones

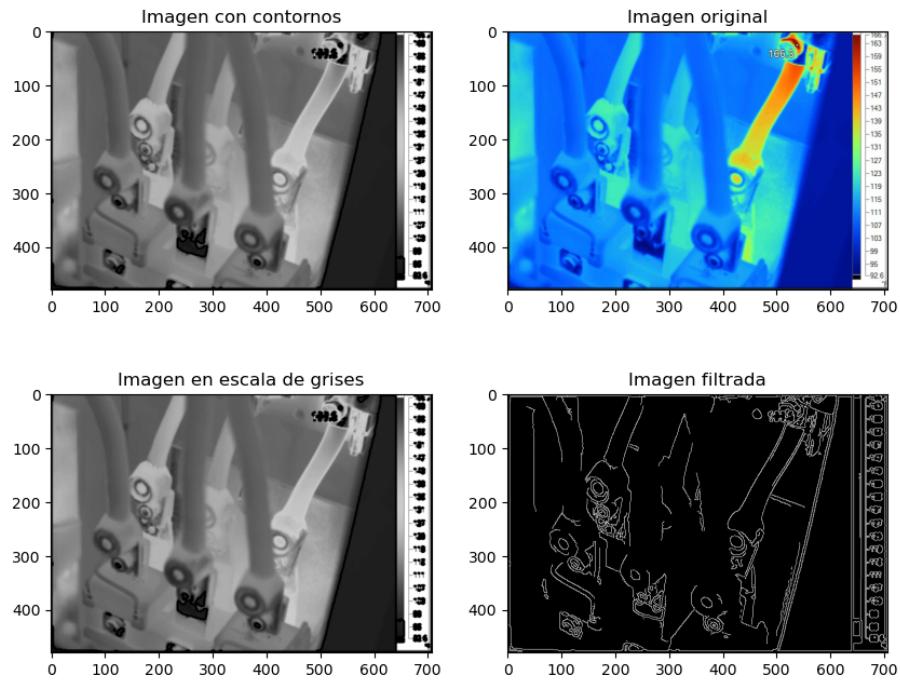


Figura 9: Segmentación basada en Regiones y Canny

Con estos resultados, se puede decir que la segmentación por medio de umbralización y la segmentación basada en regiones no es muy efectiva, esto podría ser debido a varias razones como la variabilidad en la iluminación, por las superposiciones dentro de las imágenes y/o por el ajuste de parámetros, por otro lado los bordes obtenidos con Canny son mucho mejores, pero debe ajustarse más los parámetros para no obtener segmentos no deseados.

- Color

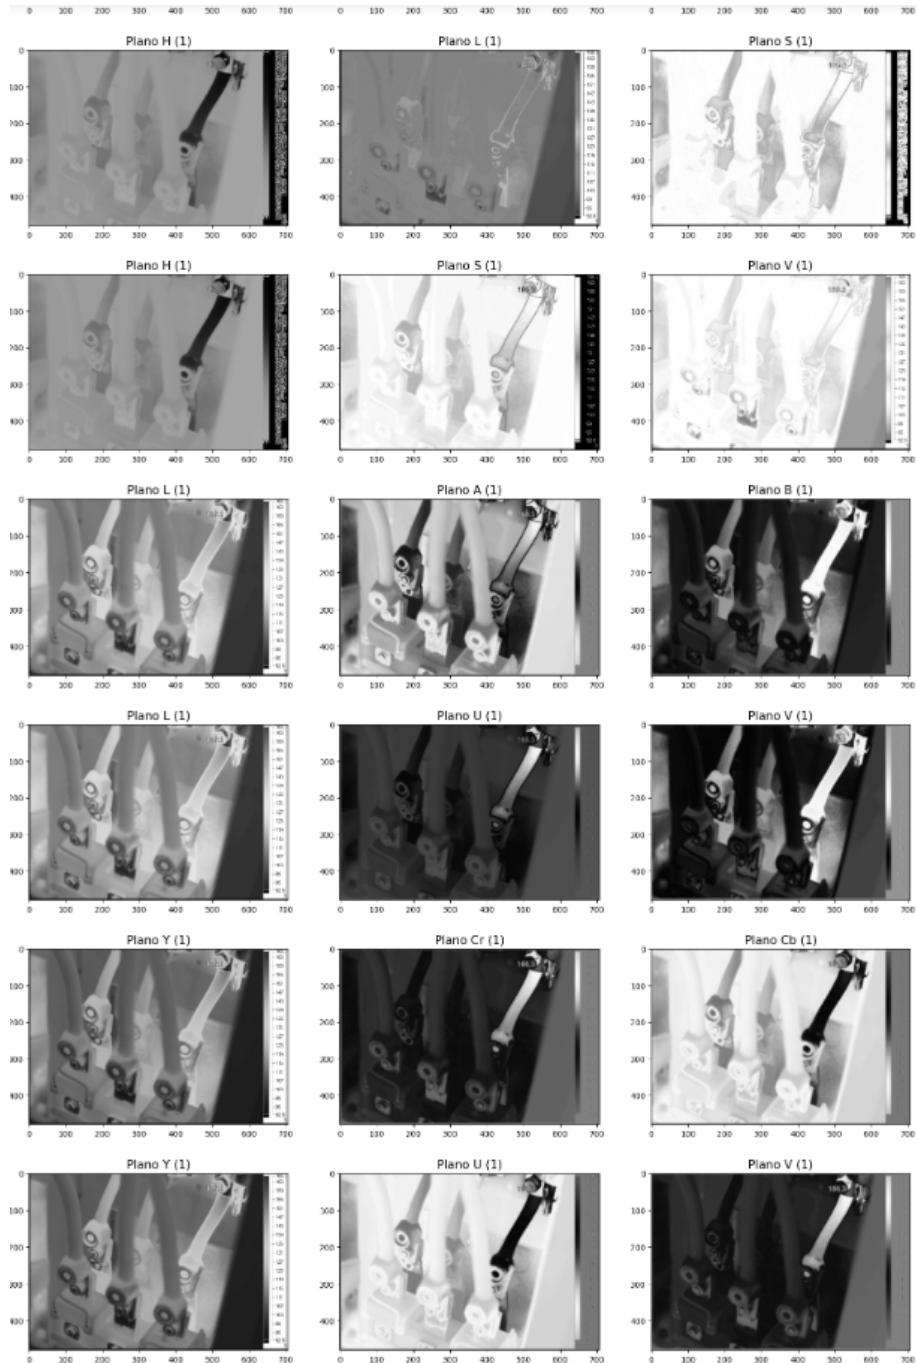


Figura 10: Diferentes representaciones de vectores de distintos modelos de Color

Se implementaron los distintos planos de color relevantes que se encuentran en OpenCV, pudiendo apreciar sus diferencias y los distintos objetos y planos del objeto en la imagen. En algunos de estos planos, se puede obtener información relevante de la termografía (zonas

con mayor temperatura), por ejemplo para el tablero 1 que tiene la paleta arcoiris los planos B, Cb, Cr H, V y Z. Por otra parte para el tablero 2 que tiene la paleta hierro, los planos que nos muestran de manera más marcada las zonas de mayor temperatura son B, H y Z. Hasta este punto, el proyecto se ha venido encausando en explorar distintas técnicas de visión de máquina en aras de delimitar que técnicas sirven para la aplicación en específico y cuáles no.

w

■ Diagrama de flujo

Posterior a esto se plantea el siguiente diagrama de flujo para cumplir los objetivos deseados:

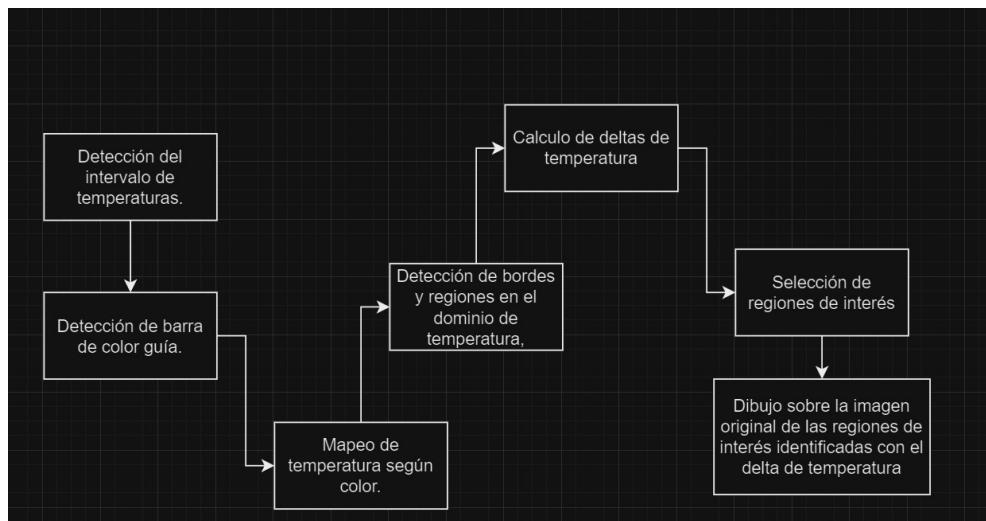


Figura 11: Estructura del proyecto

■ Obtención de Base de Datos

Aunque no está de manera explícita en el diagrama de flujo, la obtención de un dataset con múltiples termografías es importante para el desarrollo del proyecto en sí, por esto se realizaron varias tomas de imágenes termográficas o objetos de interés, en este caso, máquinas, herramientas y dispositivos asociados a la industria y la academia como paneles solares, motores, etc.

Para este propósito se usaron inicialmente dos cámaras para termografía, en este caso fueron las siguientes:

- Fluke Pt120
- Hikmicro Pocket 2



Figura 12: Cámara térmica Fluke Pt120



Figura 13: Cámara térmica Hikmicro Pocket 2

Las imágenes fueron obtenidas en su mayoría en los laboratorios de la Universidad Nacional de Colombia, como por ejemplo el Laboratorio de Máquinas Eléctricas, el de Automatización o el de Máquinas y Herramientas.

En general para la toma de las imágenes, se tomaron a procesos en máquinas que estuvieran en funcionamiento, como motores de corriente alterna, un taladro de árbol o un torno en pleno proceso de maquinado, entre otros.

A continuación se muestra un ejemplo de un torno en funcionamiento al que se le tomaron algunas imágenes, a su vez la termografía correspondiente con sus distintas zonas donde se ve claramente la diferencia de temperaturas en las distintas partes de la máquina.

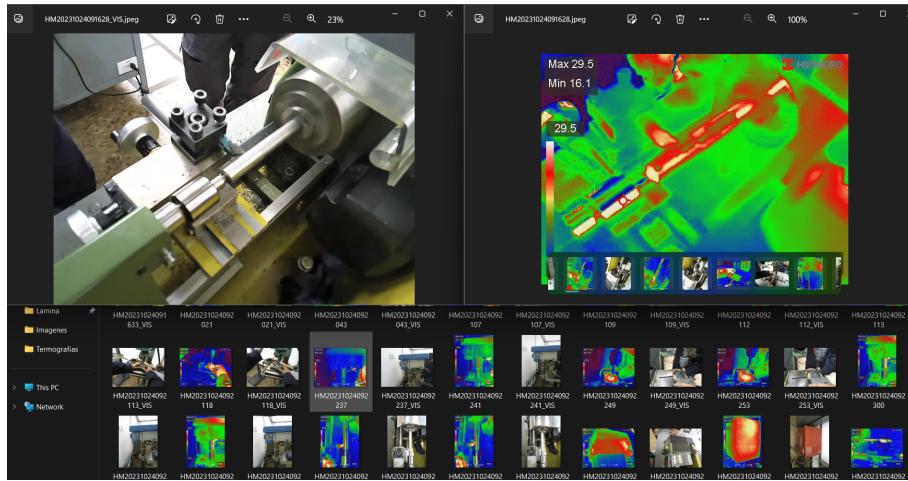


Figura 14: Ejemplo Termografía - Dataset

También podemos ver en la parte inferior de la imagen algunas otras imágenes que hacen parte del dataset obtenido hasta el momento.

- Detección de la barra de Color

Esta parte es importante para el desarrollo del proyecto, la barra de color sirve como una escala para guiar al usuario de la cámara y en general a cualquier persona que observe una termografía para identificar las zonas con mayor y menos temperatura. En la parte inicial del desarrollo se mostró dos imágenes que se usaron para explorar las herramientas de visión de máquina en este tipo de imágenes, pero a esta altura, todos los avances tendrán involucradas imágenes obtenidas directamente.

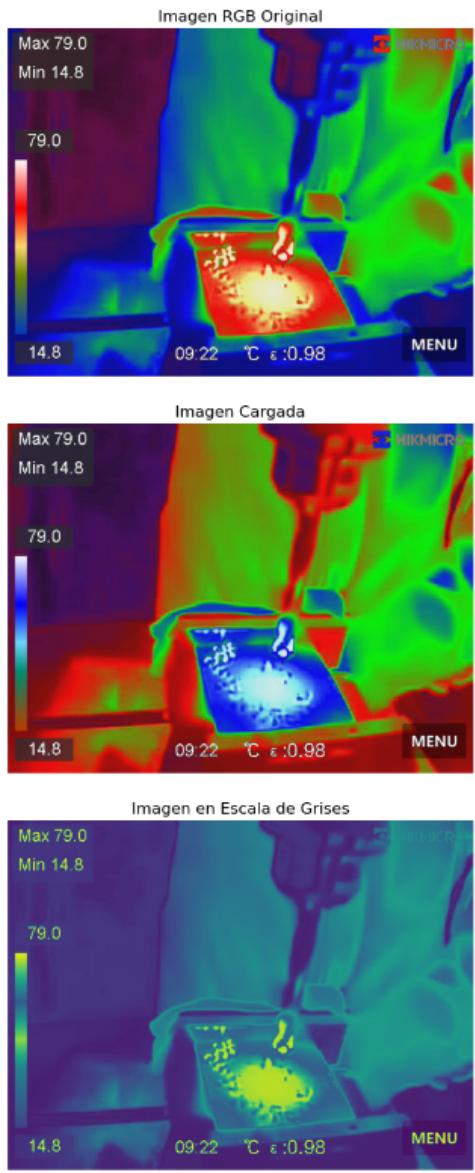


Figura 15: Carga de imágenes

Las imágenes anteriores corresponden a una de las imágenes que se usó para esta parte del proyecto y corresponde a un proceso de taladrado.

Posterior a esto se utiliza el detector de bordes Canny (`cv2.Canny`) en la imagen en escala de grises para detectar los bordes de la imagen.

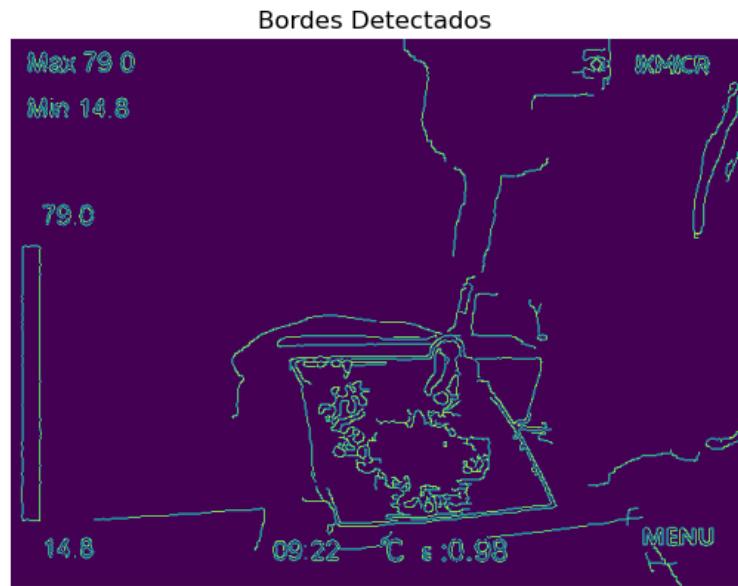


Figura 16: Detección de bordes - Escala de grises

Luego de esto se buscan los contornos en la imagen de bordes utilizando cv2.findContours, esto es de especial relevancia ya que se necesita encontrar los bordes para posteriormente detectar objetos de interés en la imagen como los números de la escala junto a la barra de color y la barra de color también.

Posterior a esto se filtran los contornos en función de su área. Solo se consideran los contornos con un área mayor a 1000 píxeles. Esto debido a que se busca el contorno cerrado correspondiente a la barra de color.

Acto seguido se dibujan rectángulos alrededor de las áreas de interés identificadas en la imagen original. Los rectángulos se dibujan en color rojo (BGR: 0, 0, 255).

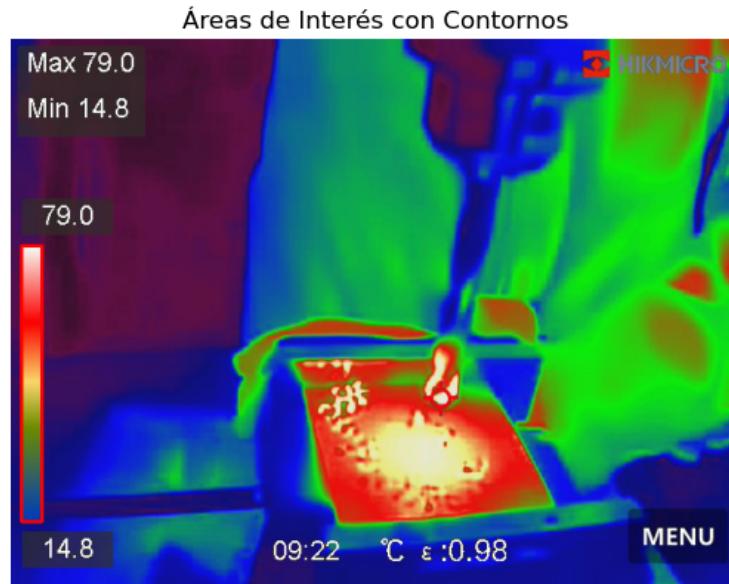


Figura 17: Detección del rectángulo correspondiente a la barra de color

En la imagen se puede ver en color rojo la generación del rectángulo que circunscribe la barra de color.

Luego, se aplica umbralización a la imagen en escala de grises utilizando cv2.threshold. Esto separa las regiones de interés del fondo.

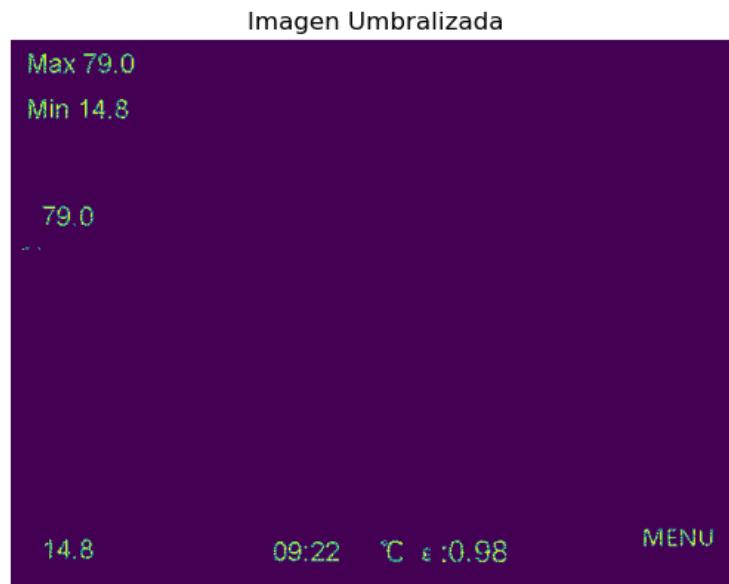


Figura 18: Umbralización

Se crea un kernel para realizar una operación de cierre morfológico en la imagen umbralizada. Esto ayuda a conectar las áreas de interés en la imagen. Se buscan contornos nuevamente en la imagen umbralizada después de aplicar la operación de cierre morfológico.



Figura 19: Cierre Morfológico

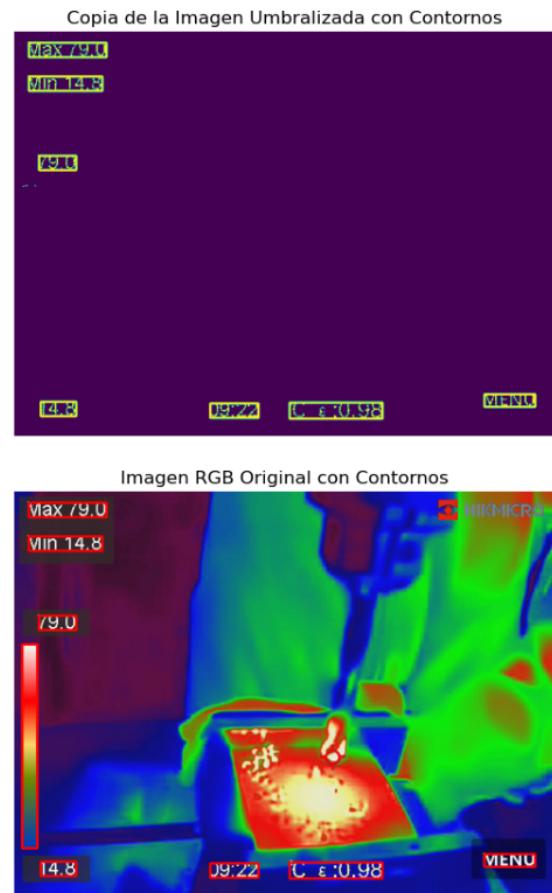


Figura 20: Imagen Original con Contornos

Se buscan rectángulos cercanos a ciertas referencias (esquinas superior derecha e inferior derecha) y se almacenan sus coordenadas en la lista (coordinatesranges).

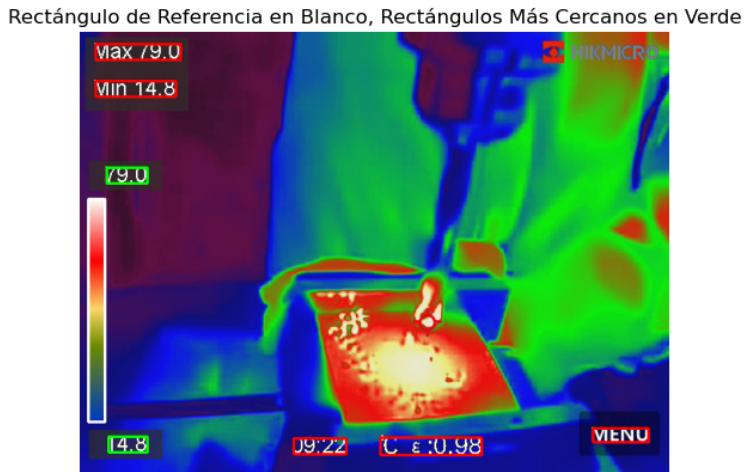


Figura 21: Selección de rectángulos de interés

Se expanden las áreas de interés (rectángulos verdes) en un 20 % y se extraen los valores de temperatura de estas áreas utilizando Tesseract OCR. Posteriormente se calcula la diferencia de temperatura (deltatemperature) entre las dos áreas de interés.

■ Espacio HSV

Se calcula el histograma del canal de matiz utilizando cv2.calcHist. El histograma muestra la distribución de los valores de matiz en la imagen. Se crea una figura de Matplotlib con tres subtramas (subplots). Cada subplot muestra diferentes aspectos del procesamiento de la imagen. Subplot 1: Muestra la imagen en el canal de matiz en color HSV. Subplot 2: Muestra la imagen en el canal de matiz en escala de grises. Subplot 3: Muestra el histograma de los valores de matiz.

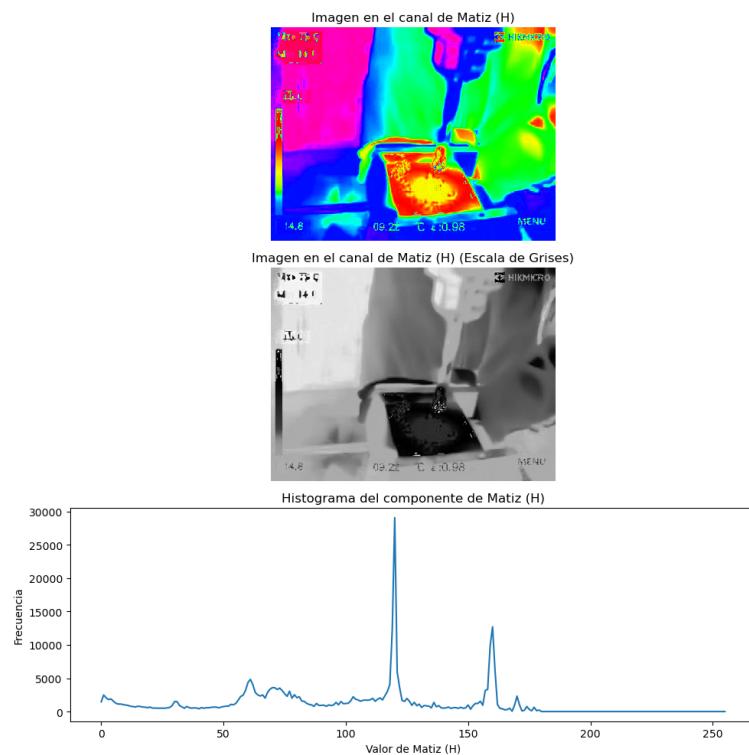


Figura 22: Umbralización

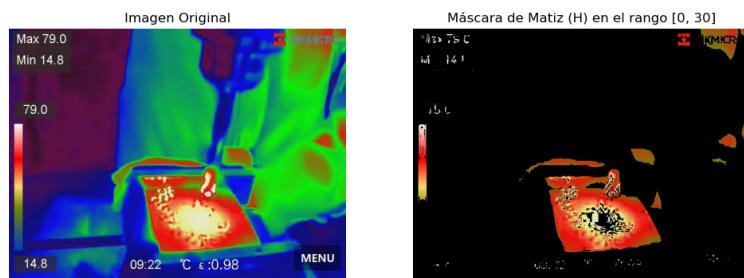


Figura 23: Espacio HSV y Plano H

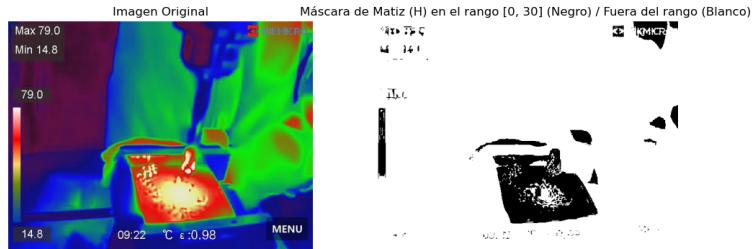


Figura 24: Espacio HSV y Plano H

Al usar este espacio obtenemos las zonas más calientes, en este caso se uso una mascara para el rango de H entre 0 30, obteniendo así las zomas nás calientes.

■ Mapeo de Colores

Por último se realiza el mapeo de los valores de matiz de la barra de colores a valores de temperatura. Esto se hace utilizando la relación entre el valor de matiz y los valores de temperatura.

La interpolación lineal se puede utilizar para asignar temperaturas a cada valor de píxel en una barra de colores. Aquí está la fórmula:

$$\text{Temperatura} = \text{TemperaturaMinima} + \left(\frac{\text{ValorDelPixel} - \text{ValorMinimo}}{\text{ValorMaximo} - \text{ValorMinimo}} \right) \times (\text{TemperaturaMaxima} - \text{TemperaturaMinima})$$

Donde:

- Temperatura: es la temperatura asociada al valor del píxel en la barra.
 - Temperatura mínima: es el valor mínimo de temperatura que tiene la termografía.
 - Valor del píxel: es el valor de intensidad del píxel en la escala de grises de la barra.
 - Valor mínimo : es el valor mínimo de intensidad de píxeles en la barra (puede ser 0 si es escala de grises).
 - Rango de valores de píxeles: es la diferencia entre el valor máximo y el valor mínimo de intensidad de píxeles en la barra.
 - Temperatura máxima: es el valor máximo de temperatura que tiene la termografía. Esto permite asignar temperaturas a cada píxel en la barra de colores basándose en su intensidad de escala de grises
- Y por último se imprime el mapeo resultante de valores de temperatura. Esto puede usarse para relacionar los valores de matiz en la barra de colores con temperaturas reales.
- Diccionario de temperaturas

Carga de la Imagen Termográfica:

Por ultimo se realiza otro mapeo pero esta vez teniendo en cuenta solo una columna para esto, la imagen se convierte del espacio de color BGR (Azul, Verde, Rojo) al espacio de color HSV (Matiz, Saturación, Valor) utilizando la función cv2.cvtColor. Esto permite trabajar con la información del matiz (H) de la imagen.

Se especifican las coordenadas y dimensiones de los rectángulos verdes expandidos, que fueron previamente detectados en la imagen.

Se calcula el rango de temperaturas en función de los valores de temperatura mínima y se crea un diccionario llamado para almacenar la información relacionada con el matiz (H) y las temperaturas asociadas en una columna de un píxel de grosor en la imagen. Se realiza un bucle que recorre los píxeles en una columna vertical que va desde el rectángulo superior al inferior y se extrae el valor del matiz (H) del píxel en el espacio de color HSV.

Se calcula la temperatura asociada al píxel en función de su posición vertical en la columna, asumiendo un cambio lineal de temperatura de abajo hacia arriba. y se almacenan los valores del matiz (H) y la temperatura calculada en el diccionario con la posición vertical (y) como clave. El resultado del código es un diccionario que contiene información clave sobre los valores de matiz (H) y las temperaturas asociadas en la columna de un píxel de grosor en la imagen.

10. CONCLUSIONES:

- Es necesario tener un dataset con imágenes en distintas condiciones de iluminación desde distintas posiciones en las instalaciones que se deseen monitorear para hacer un ajuste de parámetros más refinado.
- Es necesario mezclar varias de las técnicas usadas, como la separación en capas de colores, el filtrado para detección de bordes, la umbralización y segmentación, de esta manera se podrá obtener un mejor resultado para obtener las zonas deseadas de las imágenes termográficas.
- La calidad de las imágenes termográficas es esencial para la precisión de la detección. Las limitaciones en la resolución, la calibración y la calidad de las cámaras termográficas sumado al ruido y problemas de iluminación pueden afectar la capacidad de detectar con precisión las zonas críticas.
- La detección de zonas críticas tiene un impacto directo en la seguridad y el mantenimiento de las instalaciones industriales. Un sistema efectivo puede ayudar a prevenir problemas graves, mejorar la eficiencia del mantenimiento y, en última instancia, reducir el riesgo de accidentes y tiempo de inactividad costoso.
- El porcentaje de IRT de la cámara puede afectar la manera que se perciben los bordes y la calidad de la foto y los detalles, por lo tanto es bueno escoger un punto medio entre detalles infrarrojos y calidad en la foto, debido a que con porcentaje de IRT altos no es posible identificar claramente una imagen.
- Las diferentes marcas de cámaras térmicas usan distintos formatos de layout para su termografía, esto es un reto debido a que entre más formatos se usen, deberá iterarse más veces el reconocimiento de las características de la imagen como los rangos de temperatura y la barra de color.

11. BIBLIOGRAFIA:

- Caciotta, M., Leccese, F., Spagnolo, G. S., & Cozzella, L. (2014). Automatic industrial electrical circuit firing prevention using infrared thermography. *20th IMEKO TC4 Symposium on Measurements of Electrical Quantities: Research on Electrical and Electronic Measurement for the Economic Upturn, Together with 18th TC4 International Workshop on ADC and DCA Modeling and Testing, IWADC 2014*, 558-562.
- Ciampa, F., Mahmoodi, P., Pinto, F., & Meo, M. (2018). Recent advances in active infrared thermography for non-destructive testing of aerospace components. <https://doi.org/10.3390/s18020609>

- Didier, A. R. (2017). Aplicación de la termografía infrarroja como método de inspección no destructivo para el mantenimiento predictivo del proceso de extrusión de tubería en PVC.
- Korendo, Z., & Florkowski, M. (2001). Thermography-based diagnostics of power equipment. *Power Engineering Journal*, 15. <https://doi.org/10.1049/pe:20010104>
- Liu, F., Liu, J., & Wang, L. (2022). Asphalt Pavement Crack Detection Based on Convolutional Neural Network and Infrared Thermography. *IEEE Transactions on Intelligent Transportation Systems*, 23. <https://doi.org/10.1109/TITS.2022.3142393>
- Tomita, K., & Chew, M. Y. L. (2022). A Review of Infrared Thermography for Delamination Detection on Infrastructures and Buildings. *Sensors*, 22. <https://doi.org/10.3390/s22020423>
- Torres-Galván, J. C., Guevara, E., leazar Samuel Kolosovas-Machuca, Oceguera-Villanueva, A., Flores, J. L., & González, F. J. (2022). Deep convolutional neural networks for classifying breast cancer using infrared thermography. *Quantitative InfraRed Thermography Journal*, 19. <https://doi.org/10.1080/17686733.2021.1918514>
- Ullah, I., Khan, R. U., Yang, F., & Wuttisittikulkij, L. (2020). Deep learning image-based defect detection in high voltage electrical equipment. *Energies*. <https://doi.org/10.3390/en13020392>